



*UNIVERSIDADE FEDERAL DO RIO DE
JANEIRO*

Politécnica
UFRJ

Escola Politécnica

Departamento de Engenharia Elétrica

CONTROLE PREDITIVO BASEADO EM DEEP LEARNING DE
GEOMETRIA DE CORDÃO SIMPLES FUNDIDO POR MANUFATURA
ADITIVA ARCO ELÉTRICO

Lucas Costa Barbosa

PROJETO FINAL SUBMETIDO AO CORPO DOCENTE DO DEPARTAMENTO
DE ENGENHARIA ELÉTRICA DA ESCOLA POLITÉCNICA DA
UNIVERSIDADE FEDERAL DO RIO DE JANEIRO COMO PARTE
DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU DE
ENGENHEIRO DE CONTROLE E AUTOMAÇÃO.

Aprovada por:

Prof. Fernando Cesar Lizarralde, D.Sc.

Prof. Nome Completo, Ph.D.

Prof. Nome Completo, D.Sc.

RIO DE JANEIRO, RJ – BRASIL

OUTUBRO DE 2023

Costa Barbosa, Lucas

Controle preditivo baseado em Deep Learning de geometria de cordão simples fundido por Manufatura Aditiva Arco Elétrico/ Lucas Costa Barbosa. – Rio de Janeiro: UFRJ/Escola Politécnica, 2023.

??, ?? p. 29, 7cm.

Orientador: Fernando Cesar Lizarralde

Projeto de Graduação – UFRJ/ Escola Politécnica/ Curso de Engenharia Elétrica, 2023.

Bibliografia: p. 68 – 70.

I. Cesar Lizarralde, Fernando. II. Universidade Federal do Rio de Janeiro, UFRJ, Curso de Engenharia Elétrica. III. Controle preditivo baseado em Deep Learning de geometria de cordão simples fundido por Manufatura Aditiva Arco Elétrico.

Agradecimentos

Agradeço aos meus pais por todo o apoio e investimento na minha formação, e a todos aqueles que tem alguma parte nesse trabalho, especialmente os professores e colegas de curso. Aproveito para agradecer também a todos os amigos que me aturam até hoje e que não poderão mais fazer piada com o fato de eu não ter me formado.

Resumo do Projeto de Graduação apresentado à Escola Politécnica/UFRJ como parte dos requisitos necessários para a obtenção do grau de Engenheiro de Controle e Automação

CONTROLE PREDITIVO BASEADO EM DEEP LEARNING DE
GEOMETRIA DE CORDÃO SIMPLES FUNDIDO POR MANUFATURA
ADITIVA ARCO ELÉTRICO

Lucas Costa Barbosa

Outubro/2023

Orientador: Fernando Cesar Lizarralde

Departamento: Engenharia Elétrica

Apresenta-se neste trabalho uma aplicação de Rede Neural capaz de estimar em tempo real as características geométricas (largura e altura) de cordões simples fabricados através da Manufatura Aditivo por Arco de Arame (WAAM).

A área da Manufatura Aditiva (MA), vêm se tornando cada vez mais estudada e desenvolvida no contexto da Indústria 4.0 por conta da sua capacidade de produzir peças com geometrias complexas, reduzido uso de material, e propriedades mecânicas superiores (os chamados metamateriais).

No entanto, no contexto de WAAM as dinâmicas físicas do processo ainda são pouco conhecidas, devido a alta complexidade de modelagem, fazendo com que as peças não apresentem conformação e uniformidade geométrica. Para contornar problema são utilizados modelos aproximados que não necessariamente possuem uma boa razão performance - complexidade.

Com isso, alguns estudos utilizam modelos de *Deep Learning* (DL), as chamadas Rede Neurais (RN), para estimar as características geométricas do cordão (altura e largura) baseado nos parâmetros de solda (como corrente, tensão e velocidade de

alimentação do arame). A arquitetura utilizada foi a *Long-Short Term Memory* (LSTM), que foi acoplada a uma malha de fechada de controle funcionando como um controlador.

Abstract of Undergraduate Project presented to POLI/UFRJ as a partial fulfillment of the requirements for the degree of Control and Automation Engineer

DEEP LEARNING-BASED PREDICTIVE CONTROL OF WIRE+ARC
ADDITIVE MANUFACTURING SINGLE BEAD GEOMETRY

Lucas Costa Barbosa

October/2023

Advisor: Fernando Cesar Lizarralde

Department: Electrical Engineering

This work presents a Neural Network application capable of estimating in real time the geometric characteristics (width and height) of simple strands manufactured through Wire Arc Additive Manufacturing (WAAM).

The area of Additive Manufacturing (AM) has become increasingly studied and developed in the context of Industry 4.0 due to its ability to produce parts with complex geometries, reduced material use, and superior mechanical properties (the so-called metamaterials).

However, in the context of WAAM, the physical dynamics of the process are still little known, due to the high complexity of modeling, causing the parts to lack conformation and geometric uniformity. To work around this problem, approximate models are used that do not necessarily have a good performance-complexity ratio.

As a result, some studies use Deep Learning (DL) models, the so-called Neural Networks (RN), to estimate the geometric characteristics of the bead (height and width) based on welding parameters (such as current, voltage and wire feed speed). The architecture used was Long-Short Term Memory (LSTM) network, which was coupled to a closed control loop working as a controller.

Sumário

Lista de Figuras

Lista de Tabelas

Lista de Abreviações

CNC Controle Numérico Computadorizado

CNN Rede Neural Convolucional

DDP *Direct Deposit Parameters*

GMAW *Gas Metal Arc Weld*

GTAW *Gas Tungsten Arc Weld*

IDP *Indirect Deposit Parameters*

LSTM *Long-Short Term Memory*

MA Manufatura Aditiva

ML *Machine Learning*

MLP *Multi Layer Perceptron*

MPC *Model Predictive Control*

PAW *Plasma Arc Weld*

RNN Rede Neural Recorrente

STL *Standard Tessellation Language*

TS *Travel Speed*

WAAM *Wire+Arc Additive Manufacturing*

WFS *Wire Feed Speed*

Capítulo 1

Resultados e Discussão

1.1 Geração dos Dados

1.1.1 Simulação

A figura ?? ilustra os sinais de entrada (f e I_r) de treino e teste da simulação, utilizando os valores descritos na tabela ??:

A figura ?? ilustra os sinais de saída (w_e e h) de treino e teste da simulação

1.1.2 Dados experimentais

A figura ?? ilustra a entrada f de treino e teste dos dados experimentais:

A figura ?? ilustra a saída w_e de treino e teste dos dados experimentais:

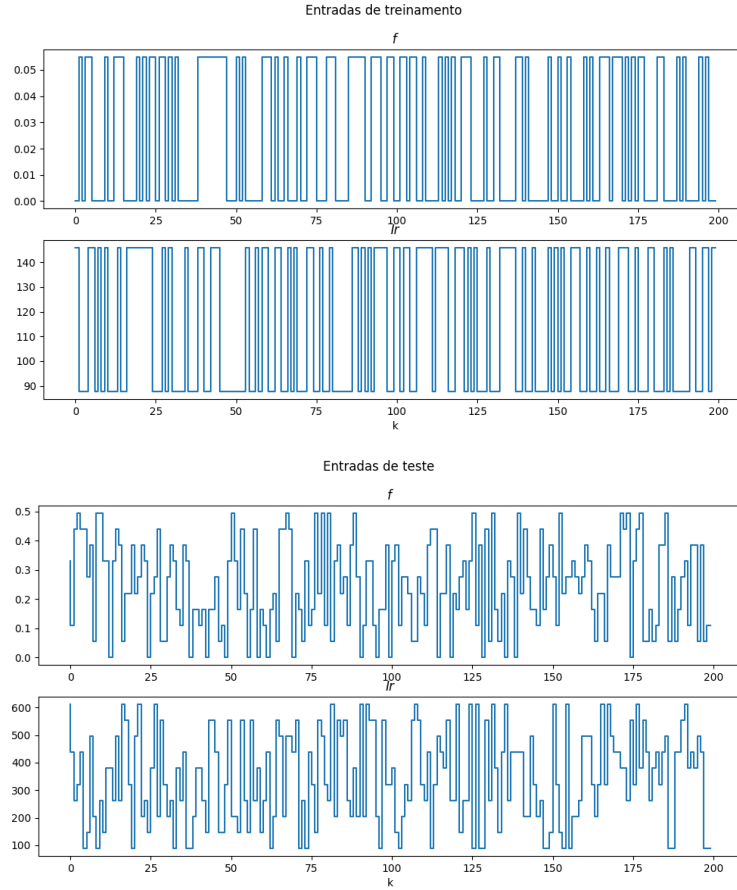


Figura 1.1: Sinais de entrada de treino (acima) e teste (abaixo) da simulação do sistema. O sinal foi truncado em 100 amostras para facilitar a visualização. Fonte: Autor

1.2 Tratamento dos Dados

1.2.1 Simulação

As figuras ?? e ?? ilustram a normalização min-max e média-desvio padrão, respectivamente, das entradas e saídas do processo.

1.2.2 Dados experimentais

As figuras ?? e ?? ilustram a normalização min-max e média-desvio padrão, respectivamente, das entradas e saídas dos dados experimentais.

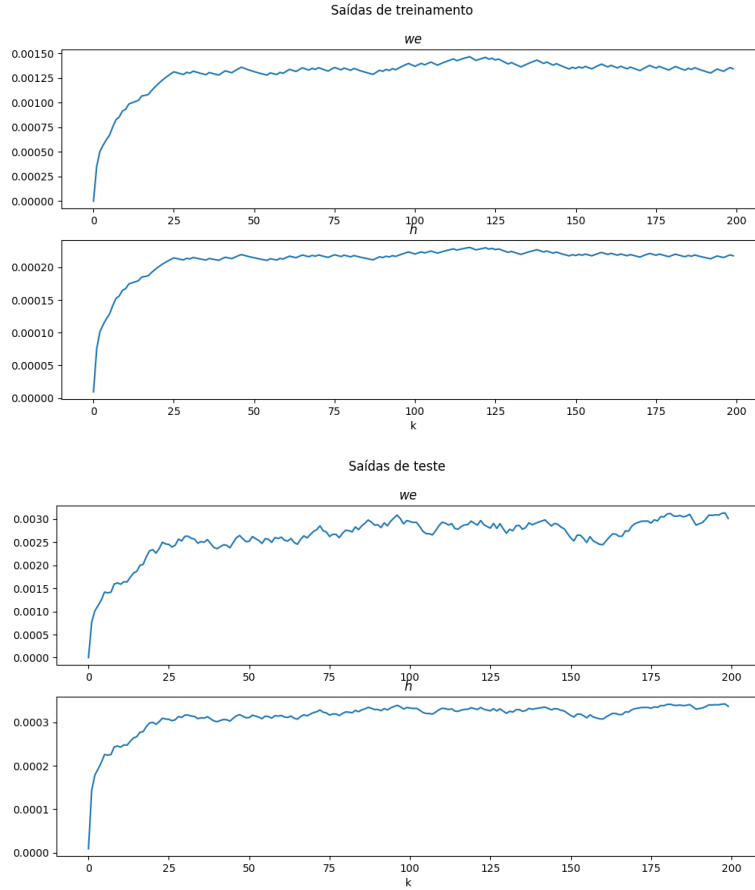


Figura 1.2: Saídas de saída de treino (acima) e teste (abaixo) da simulação. O sinal foi truncado em 100 amostras para facilitar a visualização. Fonte: Autor

1.3 Modelagem da rede LSTM

1.3.1 Ajuste dos hiperparâmetros

1.3.1.1 Simulação

As figuras ?? ilustram os resultados do treinamento dos hiperparâmetros P , Q e tamanho de batelada.

O melhor resultado é o de $(P, Q, batch_size) = (20, 25, 16)$, cujo RMSE é de 0.03. Porém, a rede com hiperparâmetros $(P, Q, batch_size) = (5, 20, 16)$ performou quase tão bem, como RMSE de 0.031, e utiliza uma janela significativa menor de pontos históricos de entrada (5) e saída (20). Isso significa que o número de parâmetros dessa rede é inferior, o que acelera seu treinamento, portanto foi a rede escolhida. Os valores vazios são de treinamentos que retornaram um erro que é um outlier e foram removidos para auxiliar na visualização do mapa de calor.




Figura 1.3: Entrada de treino (acima) e teste (abaixo) dos dados experimentais.

Fonte: Autor

1.3.1.2 Dados experimentais

As figuras ?? ilustram os resultados do treinamento dos hiperparâmetros P , Q e tamanho de batelada.

O melhor resultado é o de $(P, Q, batch_size) = (15, 45, 16)$, cujo RMSE é de 0.002. A predição dos modelos escolhidos estão descritas abaixo.

1.3.2 Predição

1.3.2.1 Simulação

A figura ?? mostra a predição das saídas do processo utilizando esta rede, num horizonte de 1000 pontos.

A performance da rede é extremamente satisfatória, mostrando que foi capaz de modelar o processo e que se torna necessário interessante modificar a modelagem




Figura 1.4: Saída de treino (acima) e teste (abaixo) dos dados experimentais. Fonte: Autor

do distúrbio. Na figura ?? está contido o histograma do erro de predição de cada saída, com a respectiva média, desvio padrão e p-valor do teste de normalidade.

Nota-se que, para ambas as saídas, o ruído de predição é normal e de média próxima a zero, indicando que o modelo foi bem sucedido em modelar o processo dinâmico em questão.

1.3.2.2 Dados experimentais

A figura ?? mostra a predição das saídas do processo utilizando esta rede, num horizonte de 1000 pontos.

A performance da rede é extremamente satisfatória, mostrando que foi capaz de modelar o processo e que se torna necessário interessante modificar a modelagem do distúrbio. Na figura ?? está contido o histograma do erro de predição de cada saída, com a respectiva média, desvio padrão e p-valor do teste de normalidade.

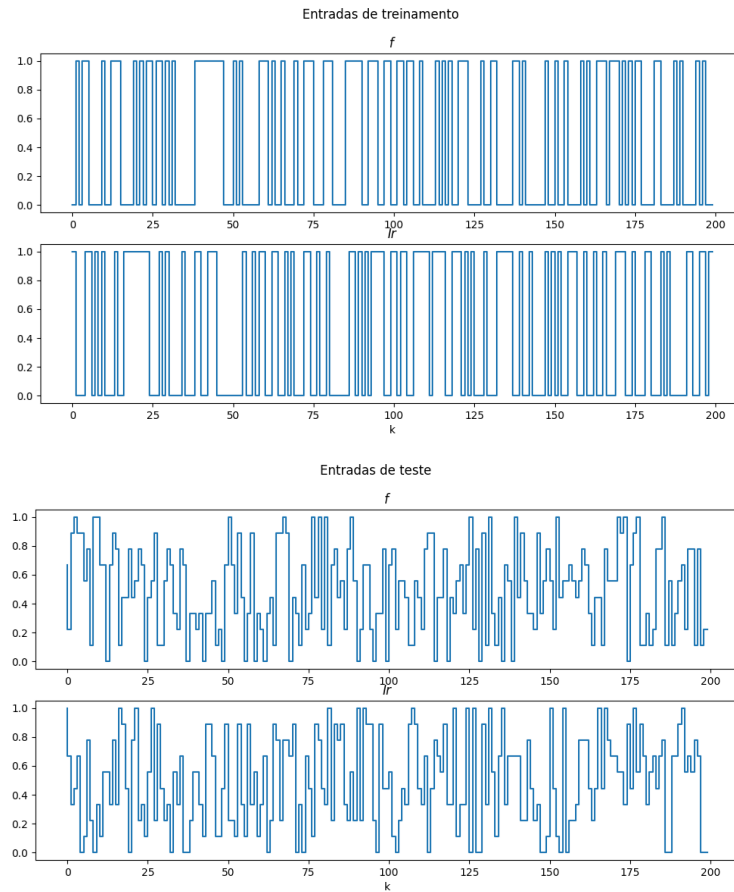


Figura 1.5: Sinais normalizados de treino (acima) e teste (abaixo) utilizados como entrada da simulação do sistema. O sinal foi truncado em 100 amostras para facilitar a visualização. Fonte: Autor

Nota-se que, para ambas as saídas, o ruído de predição é normal e de média próxima a zero, indicando que o modelo foi bem sucedido em modelar o processo dinâmico em questão.

1.4 Controle MPC

As figuras ?? e ?? ilustram os sinais de controle otimizados via MPC e as saídas controladas, respectivamente.

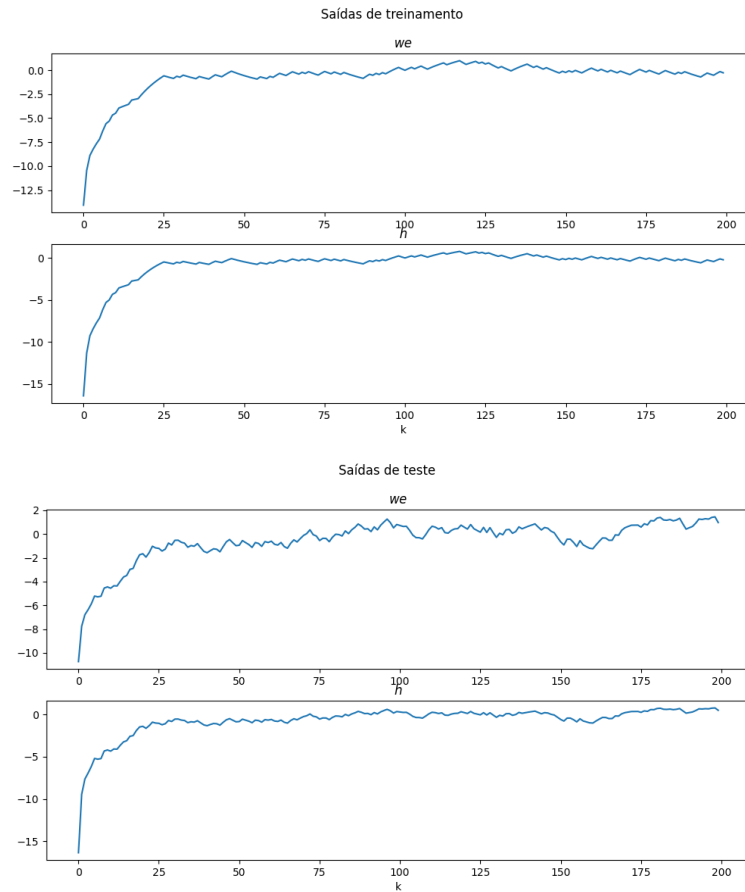


Figura 1.6: Saídas normalizadas de treino (acima) e teste (abaixo) da simulação. O sinal foi truncado em 100 amostras para facilitar a visualização. Fonte: Autor

A implementação foi capaz de controlar as saídas em torno de um referencial determinado. A oscilação de controle e saída estão dentro do aceitável considerando os limites físicos do processo. A tabela ?? descreve as métricas do controle do processo.




Figura 1.7: Sinais normalizados de treino (acima) e teste (abaixo) de entrada dos dados experimentais. Fonte: Autor

Saída	Overshoot (%)	RMSE	$\Delta \bar{u}/u_{max}(\%)$
w_e	12.82	$6.28 \cdot 10^{-9}$	1.8
h	8.14	$7.23 \cdot 10^{-11}$	1.4

Tabela 1.1: Métricas de controle MPC do processo GMAW estabelecido




Figura 1.8: Sinais normalizados de treino (acima) e teste (abaixo) de saída dos dados experimentais. Fonte: Autor

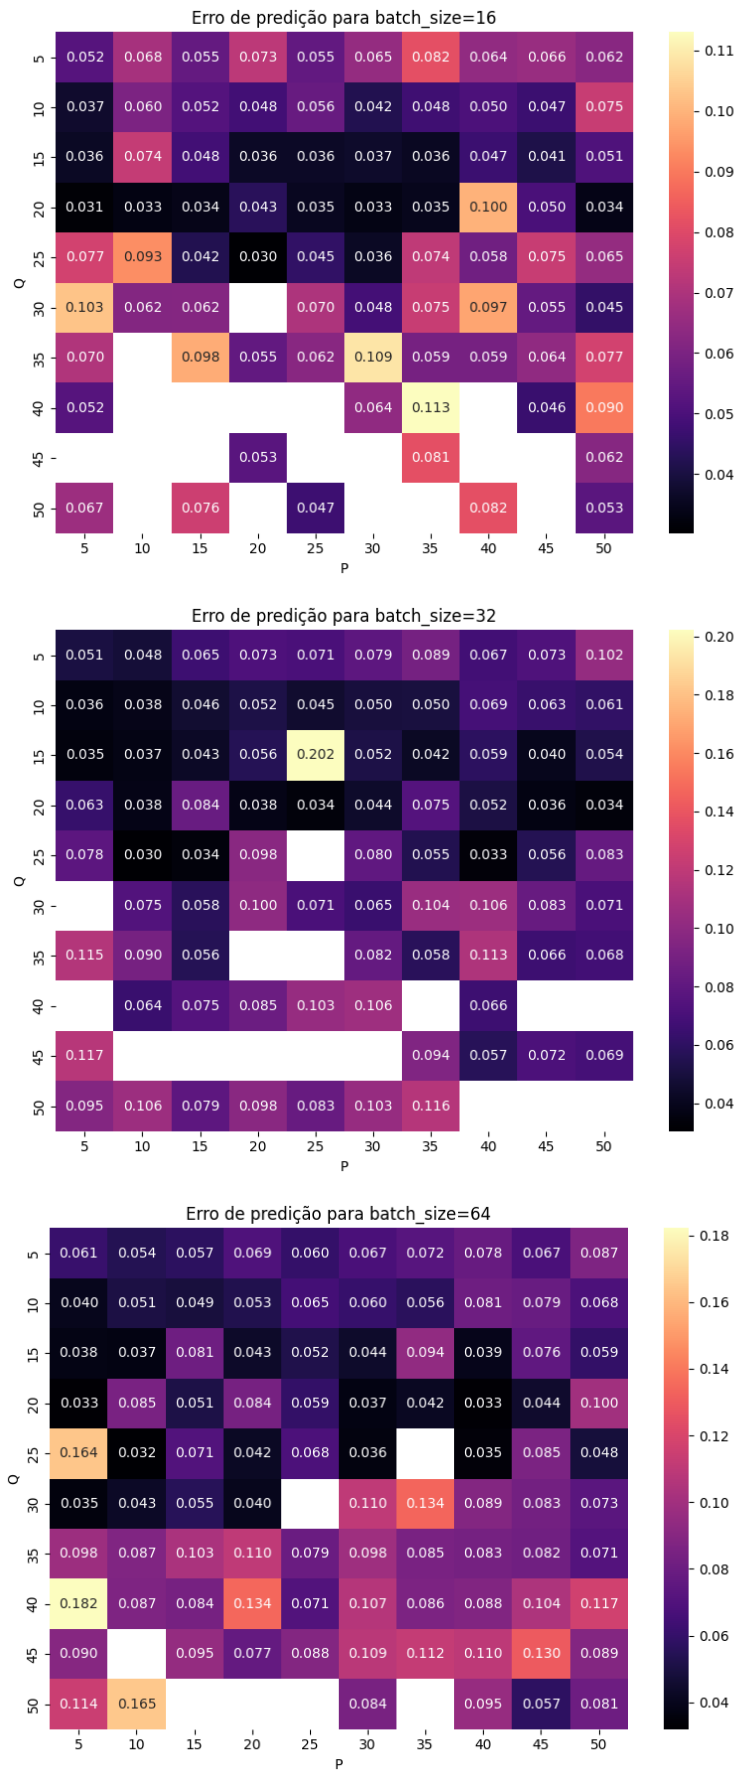


Figura 1.9: Mapa de calor de treinamento do modelo referente aos dados de simulação, indicando o erro RMS para diferentes valores de P e Q e para tamanho de batelada 16 (acima), 32 (centro) e 64 (abaixo). Fonte: Autor

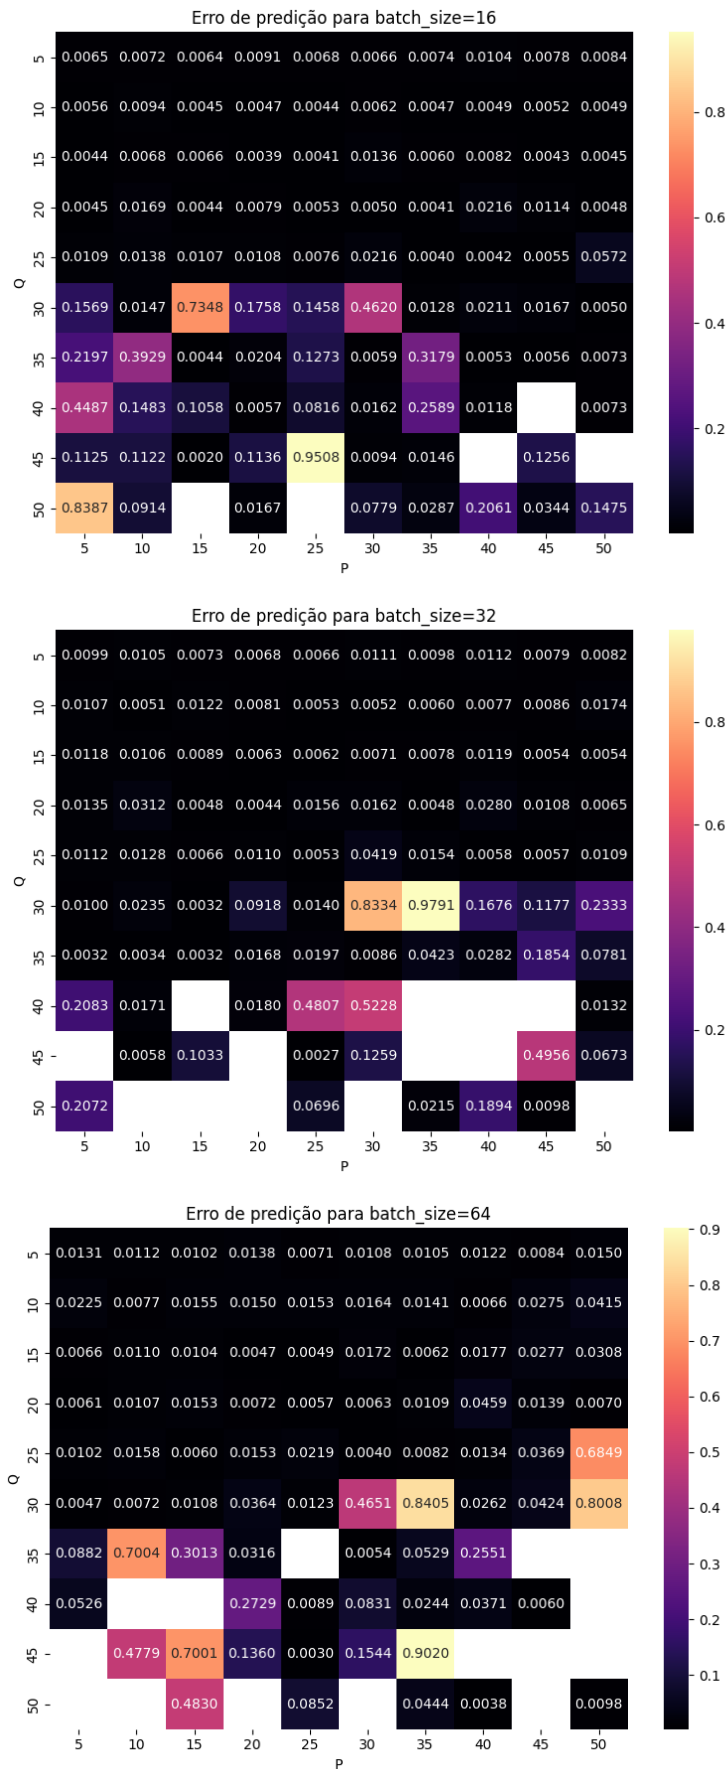


Figura 1.10: Mapa de calor de treinamento do modelo referente aos dados experimentais, indicando o erro RMS para diferentes valores de P e Q e para tamanho de batelada 16 (acima), 32 (centro) e 64 (abaixo). Fonte: Autor

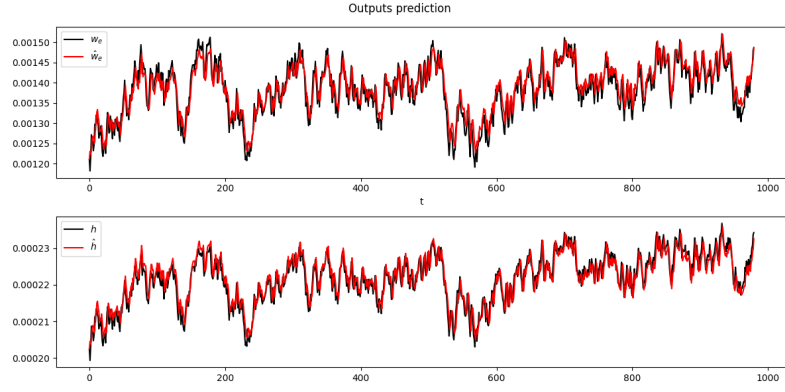


Figura 1.11: Predição das duas saídas da simulação utilizando a rede com hiperparâmetros $P = 20$, $Q = 25$ e tamanho de batelada 16. Fonte: Autor

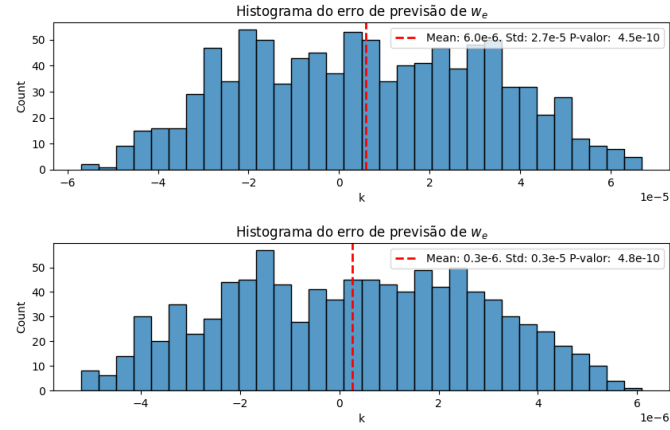


Figura 1.12: Histograma do erro de predição de cada saída, indicando a média, desvio padrão e valor-p do teste de normalidade Shapiro [2]. Fonte: Autor.




Figura 1.13: Predição da saída dos dados experimentais utilizando a rede com hiperparâmetros $P = 15$, $Q = 45$ e tamanho de batelada 16. Fonte: Autor

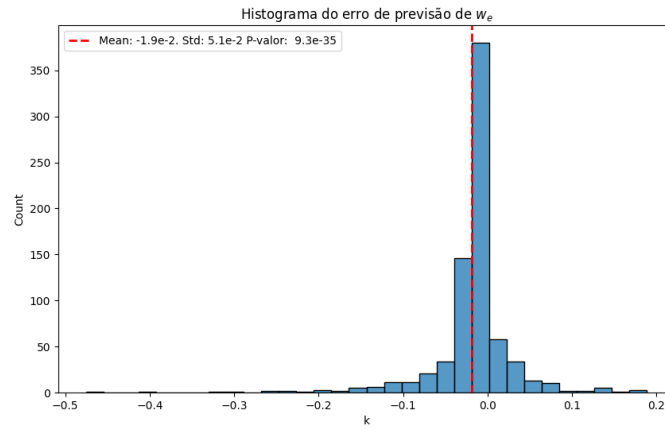


Figura 1.14: Histograma do erro de previsão da saída dos dados experimentais, indicando a média, desvio padrão e valor-p do teste de normalidade Shapiro [2].

Fonte: Autor.

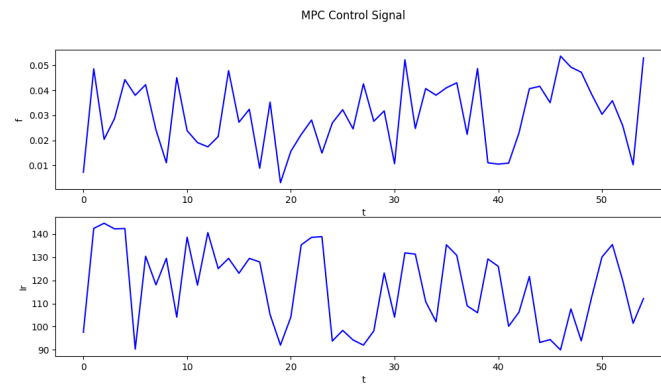


Figura 1.15: Sinais de controle via MPC. Fonte: Autor.

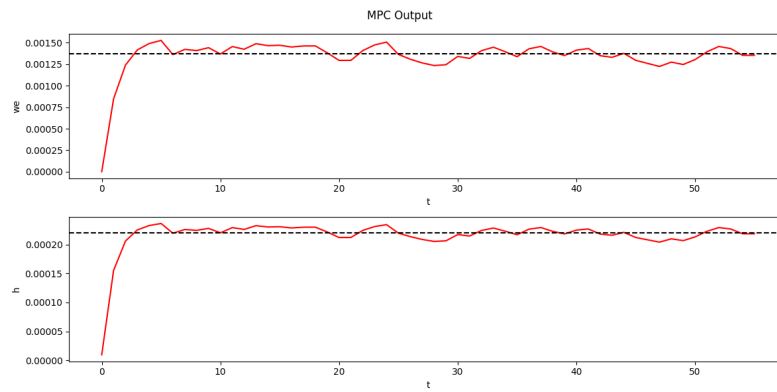


Figura 1.16: Saídas controladas pelo MPC. Fonte: Autor.

Capítulo 2

Conclusões

Com o intuito de lidar com um problema de controle multivariável de um processo GMAW, que possui dinâmica não linear, este trabalho propôs um controle preditivo (MPC) baseado em DL (LSTM-NMPC).

Primeiramente, foi realizada a simulação do processo GMAW, utilizando as equações dinâmicas de [1], e os dados foram tratados usando a normalização e padronização das entradas e saídas.

Depois, uma RN baseada na arquitetura LSTM foi treinada com o intuito de modelar o processo GMAW, ajustando-se os seus hiperparâmetros através da busca em grade.

Por fim, o melhor modelo foi utilizado dentro do MPC para otimizar o controle da geometria do cordão através de um algoritmo de GD adaptativo. O controle proposto foi provado estável, através de análise teórica.

O framework do MPC desenvolvido neste trabalho pode ser usado para se comunicar com o robô através do protocolo de comunicação do ROS.

O framework do MPC desenvolvido neste trabalho pode ser aplicado para qualquer controle preditivo de um processo não linear, apenas refazendo o treinamento com uma nova base de dados específica.

Referências

- [1] BENDIA, Rafael M; LIZARRALDE, Fernando; COUTINHO, Fernando G. Multivariable closed-loop control for layer geometry in Wire Arc Additive Manufacturing. In: 1. SIMPOSIO Brasileiro de Automacao Inteligente-SBAI. [S.l.: s.n.], 2021. v. 1.
- [2] SHAPIRO, Samuel Sanford; WILK, Martin B. An analysis of variance test for normality (complete samples). **Biometrika**, JSTOR, v. 52, n. 3/4, p. 591–611, 1965.